

Pregunta de recerca

Repetint l'entrenament amb diferents particions de dades, quin model supervisat (KNN, regressió logística o arbre de decisió) és més precís a l'hora de predir cadascun dels tres datasets (Telco, Iris i Wine)? Quant varia el resultat entre les diferents particions? Afecten el resultat l'escalat de les dades i la mida del dataset?

Extra

Pot un model no supervisat (K-Means) assolir resultats comparables als dels models supervisats quan s'avalua amb mètriques externes, i per què aquesta comparació no és equitativa?

Hipotesis:

En iris i wine, al ser datasets de casi el mismo numero de filas, los 3 modelos seran muy parecidos. En cambio, en Telco, al ser tan grande y con tantos campos, el arbol de decision no será muy preciso, en cambio la regresión logisitica superar a los 2 modelos.

El resultat dependra mes de la quantitat del dataset mes queu de les reparticions, ja que com mes gran sigui el dataset. menys variabilitat tindra entre totes les dades, ja queu cobrira gran part dels valors. Aixi que datasets com Iris o Wine tindran mes variabilitat entre reparticions. L'escalat de dades afectara el resultat ja que els valors mes grans no afectaran exageradament al resultat si els altres son molt petits, amb un escalat de 0 i 1, els valors seran molt mes precisos.

extra

Kmeans quedara per sota dels altres models ja que al no rebre les etiquetes, la comparativa no seria res justa.

Part de comentament i analisis dels resultats:

Per a la part d'analisi dels resultats, es comentaran i comparara la hipotesis amb la realitat. També es parlara de les possibles causes, sigui la hipotesis encertada o no. S'adentrara superficialment en la part mes algebraica dins dels modelos. Per poder reforçar mes l'analisi. I s'acabara concluint el treball amb ...